

Propuesta de Trabajo: Sistema de Seguridad para Modelos de IA

Objetivo: Desarrollar un sistema de detección y bloqueo de prompts peligrosos para prevenir que modelos de IA generen contenido dañino, engañoso o ilegal, garantizando su uso seguro y alineado.

Alcance: Clasificación de prompts en tiempo real como seguros o peligrosos. Incluye detección de jailbreaking, inyección de código, extracción de datos y red teaming. Optimizado para hardware limitado.

Metodología:

1. Preprocesamiento: Tokenización y análisis semántico con embeddings (Sentence-BERT).
2. Modelo: Arquitectura híbrida (Transformer ligero + Random Forest) para clasificación binaria.
3. Entrenamiento: Fine-tuning con datasets de prompts maliciosos y seguros.
4. Evaluación: Accuracy, precision, recall, F1-score y AUC-ROC.

Datasets: Entrenamiento: AdvBench (10,000 prompts maliciosos) + HarmBench (8,000 prompts peligrosos). Validación: JailbreakBench (5,000 prompts) + Red Teaming Prompts (3,000 prompts). Prueba: Prompts generados manualmente y de competencia de alineación.

Tecnologías: Python, Hugging Face Transformers, Scikit-learn, Sentence-BERT, NLP.

Cronograma: Semanas 1-2: Recolección, etiquetado y preprocesamiento de datos. Semanas 3-4: Entrenamiento y validación del modelo. Semana 5: Optimización, pruebas de estrés y ajuste de umbrales. Semana 6: Documentación y despliegue como API.

Impacto Social: Proteger sistemas de IA de usos malintencionados, prevenir generación de contenido dañino y garantizar el cumplimiento de estándares éticos y legales.

Requisitos de Hardware: CPU 4 núcleos, RAM 8GB, almacenamiento 25GB.

Resultados Esperados: Modelo con 93% accuracy, latencia menor a 500ms, integración como middleware para APIs de IA, lista dinámica de patrones bloqueados.